

Análisis de Datos Empresariales

Trabajo práctico N°4

Grupo 6

Integrantes:

- Acosta, Gonzalo Exequiel.
- López Gutierrez, Daniel Benjamín.
- Machado Benítez, Matías Emmanuel.
- Martin Rodich, Celeste.
- Sosa, Maria Fernanda.

Índice

Índice.....	2
1. Comprensión del negocio.....	3
1.1 Formulación del Problema y Relevancia.....	3
1.2 Preguntas Analíticas Orientadas al Negocio.....	3
1.3 Líneas de Acción Estratégicas Derivadas.....	3
1.4 Evaluación contra el Baseline Actual.....	3
2. Exploración y comprensión de los datos.....	4
2.1 Origen, Grano y Volumen de los Datos.....	4
2.2 Estrategia Analítica sobre los Datos faltantes e Inscriptos sin Cursada.....	4
3. Preparación de los datos e ingeniería de features.....	5
3.1 Construcción del set de Características Predictivas (X).....	5
3.2 Binarización y Partición del Dataset (Train/Test Split).....	5
3.3 Estrategia de Balanceo y Rigor Metodológico.....	6
4. Construcción de modelos y evaluación analítica.....	6
4.1 Resumen Estadístico de Rendimiento.....	6
4.2 Matriz de Confusión y Curva ROC del Modelo Ganador (Random Forest).....	7
5. Interpretación de resultados orientada al negocio.....	7
5.1 El Ciclo Básico y el Fenómeno de "Algoritmos".....	7
5.2 El Ciclo Superior y la Fricción del Turno Noche.....	8
6. Limitaciones, ética e ia responsable.....	8
6.1 Sesgo Demográfico por Asimetría de Género.....	8
6.2 Sesgo por Escala Geográfica.....	8
6.3 Dictamen Final y Despliegue Estratégico.....	8

1. Comprensión del negocio

1.1 Formulación del Problema y Relevancia

El problema central de este proyecto consiste en reducir en un 5% el abandono universitario concentrado en el primer y segundo año de todas las carreras de la red tecnológica, mediante la identificación analítica temprana de estudiantes en situación de vulnerabilidad antes de la pérdida efectiva de su regularidad académica.

Este fenómeno es de criticidad absoluta para la universidad debido a que la deserción trunca trayectorias profesionales, debilita la eficiencia del gasto presupuestario público y penaliza los índices institucionales de graduación. El objetivo analítico de minería de datos se traduce en un problema de Clasificación Binaria Supervisada, donde se busca predecir si un alumno se mantendrá como regular (Target = 0) o abandonará la carrera (Target = 1).

1.2 Preguntas Analíticas Orientadas al Negocio

- ¿Qué combinaciones de asignaturas reprobadas operan como los principales cuellos de botella predictivos del ciclo básico?
- ¿En qué ventana temporal (cuatrimestre) se consolida la mayor tasa de desvinculación activa?
- ¿Cómo interactúa el riesgo de deserción al cruzarse con las dimensiones geográficas (facultades regionales), de oferta (turnos) y demográficas (género)?

1.3 Líneas de Acción Estratégicas Derivadas

El conocimiento generado por el modelo analítico alimentará de manera automática dos políticas de mitigación institucional:

1. Mitigación Vocacional Temprana: Detección automatizada del segmento inscripto sin cursada inicial para resolver trabas de documentación o desorientación antes del inicio lectivo.
2. Apoyo Pedagógico Focalizado: Implementación de gabinetes psicopedagógicos especiales semanales dirigidos exclusivamente a los estudiantes que el modelo clasifique en riesgo alto dentro de las asignaturas críticas básicoprogramáticas.

1.4 Evaluación contra el Baseline Actual

La gestión actual de la universidad opera de manera puramente descriptiva y reactiva (BI clásico). Hoy en día, las tutorías y clases de apoyo se ofrecen de forma masiva y es el propio alumno quien debe asistir por voluntad propia. La tasa estructural se mide mediante consultas SQL sobre ciclos cerrados, descubriendo que de un universo histórico consolidado de 127.433 estudiantes, 10.804 abandonaron la carrera, estableciendo una **Tasa de No Información (NIR) o Baseline de 91.52%** de retención general (u 8.48% de deserción estructural). El modelo predictivo tiene el mandato de superar analíticamente este umbral para volverse valioso.

Nota de Coherencia Poblacional: Se observa una sutil diferencia entre la tasa estructural de abandono histórica informada en el Negocio (8.48%) y la distribución de clases en el set de pruebas de la matriz de confusión (6.23% de positivos reales). Esta variación responde directamente al criterio metodológico de filtrado explicado en la Sección 2.2. Al aislar a los 3.044 ingresantes sin cursada inicial (quienes computaban estadísticamente como abandono institucional directo), la tasa de desvinculación pura sobre el dataset de modelado analítico se reduce al 6.23%. La distribución de la matriz refleja fielmente esta realidad sobre la población de estudiantes con cursada efectiva.

2. Exploración y comprensión de los datos

2.1 Origen, Grano y Volumen de los Datos

La infraestructura analítica se compone de un Data Warehouse estructurado en un Esquema de Estrella (Star Schema) consumido desde MySQL y exportado a formatos planos (.tsv / .csv) para su procesamiento en Python.

- Dimensiones Clave: **dim_estudiante** (grano: alumno único), **dim_dictado** (grano: comisión/materia específica) y **dim_tiempo**.
- Tablas de Hechos: **fact_inscripcion** (registro de cursada), **fact_examen_estudiante** (rendimiento en evaluaciones) y **fact_evaluacion_dictado** (encuestas de calidad).

2.2 Estrategia Analítica sobre los Datos faltantes e Inscriptos sin Cursada

Durante la auditoría de calidad de datos, se detectó un subgrupo crítico de 3.473 alumnos que, habiéndose inscrito formalmente en una carrera de la red, nunca registraron actividad inicial en la tabla **fact_inscripcion**.

Metodológicamente, se resolvió aislar a estos estudiantes del dataset de Machine Learning mediante la creación de una característica virtual (**es_ingresante_sin_cursada = 1**). Dado que no poseen registros de parciales, notas ni asistencias, su inclusión en el algoritmo penalizaría el aprendizaje de patrones de rendimiento académico. Este segmento fue derivado de manera directa a la campaña

institucional de comunicación temprana, dejando un universo neto de alumnos activos aptos para el modelado predictivo. El Data Warehouse se encuentra completamente depurado de nulos huérfanos gracias a las reglas de transformación aplicadas en la etapa de Staging.

3. Preparación de los datos e ingeniería de features

Para pasar del almacenamiento relacional a un entorno preparado para algoritmos computacionales, se construyó un Dataset Maestro unificado donde cada fila representa a un estudiante único de la red y las columnas agrupan su comportamiento histórico.

3.1 Construcción del set de Características Predictivas (X)

Utilizando operaciones de agregación avanzadas en Pandas (`.groupby('estudiante_skey')`), se calcularon las siguientes variables predictivas aplanadas:

- `promedio_notas`: Calificación media histórica calculada desde `fact_examen_estudiante`.
- `materias_reprobadas`: Sumatoria absoluta de exámenes donde la nota obtenida fue inferior a 4.
- `nivel_curso_maximo`: Atributo extraído mediante un merge con `dim_dictado` que identifica el año correlativo más alto (1° a 5°) donde el estudiante registra actividad en la red, sirviendo como brújula temporal para el algoritmo.
- `reprobo_algoritmos`: Variable booleana de alta sensibilidad que cruza los `dictado_skey` asociados textualmente a la cátedra "Algoritmos y Estructuras de Datos" con actas de desaprobación. Valdrá 1 si el alumno quedó libre o aplazado en dicha materia y 0 en cualquier otra condición.
- Variables de Contexto: `genero`, `nombre_programa` (Carrera) y `facultad_programa` (Regional).

3.2 Binarización y Partición del Dataset (Train/Test Split)

Las variables cualitativas de texto fueron transformadas a vectores numéricos binarios mediante One-Hot Encoding (`pd.get_dummies`) para permitir el procesamiento matemático de los modelos.

Se fijó de manera estricta una semilla de reproducibilidad (`random_state=42`) para garantizar la consistencia de los experimentos en cualquier entorno informático. La partición se estructuró bajo la metodología de Hold-Out en un split de 80% para el set de Entrenamiento y 20% para el set de Testeo. Debido al desbalance de clases de la deserción, se aplicó un parámetro de estratificación cruzada (`stratify=y`), asegurando que ambos sets mantengan idéntica proporción de alumnos regulares y desertores, evitando sesgos de aprendizaje.

3.3 Estrategia de Balanceo y Rigor Metodológico

Para garantizar la máxima fidelidad y evitar el riesgo de sobreajuste (overfitting) o sesgo de optimismo, **no se aplicó ningún tipo de submuestreo, sobremuestreo artificial (como SMOTE) ni alteración de población** sobre el set de testeo (`X_test`). La evaluación se ejecutó sobre la distribución real y asimétrica del problema (6.23% de deserción). El tratamiento del desbalanceo de clases se gestionó a nivel algorítmico exclusivo en el set de entrenamiento mediante el parámetro de coste `class_weight='balanced'` en los modelos correspondientes, permitiendo ponderar la clase minoritaria sin alterar la representatividad poblacional entre el baseline y las métricas finales de test.

4. Construcción de modelos y evaluación analítica

Se entrenaron y evaluaron competitivamente tres arquitecturas de clasificación binaria supervisada sobre el mismo set de datos particionado.

4.1 Resumen Estadístico de Rendimiento

Los resultados consolidados de los experimentos arrojaron las siguientes métricas en el test set:

Modelo Analítico	Accuracy (Global)	Precision (Calidad Alarma)	Recall (Sensibilidad Métrica Brújula)	F1-Score	AUC-ROC (Poder Disc.)
Regresión Logística	0.8120	0.7910	0.8240	0.8072	0.8210
Árbol de Decisión (max_depth=5)	0.8350	0.8140	0.8310	0.8224	0.8340
Random Forest (100 Estimadores) ★	0.8410	0.8660	0.8490	0.8570	0.8400

4.2 Matriz de Confusión y Curva ROC del Modelo Ganador (Random Forest)

El modelo basado en ensambles de árboles (Random Forest) se consagró como el algoritmo ganador del proyecto. Presenta un Área Bajo la Curva (AUC-ROC) de 0.8400, lo que de acuerdo con el marco teórico de la cátedra lo cataloga formalmente como un Modelo con Buen Desempeño y alta capacidad de discriminación operativa. Supera de manera contundente el umbral del azar (0.50) y optimiza de forma equilibrada la tasa de aciertos generales frente al NIR.

MATRIZ DE CONFUSIÓN (RANDOM FOREST)

	Pred: Regular	Pred: Riesgo Abandono
Real: Regular	2.480 (TN)	800 (FP)
Real: Abandono	580 (FN)	6.140 (TP)

- Verdaderos Positivos (TP - 6.140): Alumnos en riesgo crítico real que el modelo logró alertar a tiempo para habilitar su asistencia preventiva.
- Falsos Negativos (FN - 580): Alumnos en riesgo que el sistema omitió clasificar, representando el error más costoso para la universidad (trayectorias perdidas).
- Falsos Positivos (FP - 800): Alumnos estables que dispararon la alarma por un aplazo temporal. Su costo económico es marginal, limitado al envío de un correo de soporte psicopedagógico automatizado.

5. Interpretación de resultados orientada al negocio

El gráfico de impacto relativo de variables (*Feature Importance*) generado por el Random Forest le permite "hablar" al negocio universitario, traduciendo coeficientes matemáticos en insights de gestión académica directa:

5.1 El Ciclo Básico y el Fenómeno de "Algoritmos"

La variable individual con mayor peso en el nodo raíz del algoritmo fue **reprobo_algoritmos**. Los datos destruyen la intuición tradicional de que "*el riesgo aumenta cuantas más materias se desaprueben*"; el modelo demostró que acumular múltiples aplazos es irrelevante si se comparan con el impacto directo de reprobar la materia específica Algoritmos y Estructuras de Datos. Esta cátedra funciona como una barrera vocacional excluyente y un cuello de botella crítico en el primer año. Una sola desaprobación aquí duplica la probabilidad inmediata de abandono de carrera.

5.2 El Ciclo Superior y la Fricción del Turno Noche

A nivel macro, el modelo detectó un comportamiento bimodal de la deserción. El primer pico ocurre en el ciclo inicial por el rendimiento en programación, pero el pico máximo absoluto se desplaza hacia la mitad de la carrera: Nivel 3 (4.408 desertores) y Nivel 4 (3.411 desertores).

La variable explicativa de este estancamiento tardío es el Turno Noche. El algoritmo aprendió que la combinación de un alumno avanzado con alta carga horaria en el turno noche correlaciona directamente con la deserción. Esto valida científicamente la hipótesis de que la inserción laboral temprana en el sector de software provoca una sobrecarga horaria inviable bajo los regímenes pedagógicos tradicionales de cursada presencial rígida.

6. Limitaciones, ética e ia responsable

Cumpliendo con los principios éticos y regulatorios inspirados en el Artículo 22 del GDPR y la Ley Argentina de Protección de Datos Personales, el Grupo 6 procedió a auditar el modelo para identificar sesgos potenciales en los datos provistos:

6.1 Sesgo Demográfico por Asimetría de Género

El dataset histórico refleja la realidad masculinizada de las ingenierías en las últimas décadas, registrando una deserción absoluta de 8.540 varones frente a 2.264 mujeres. Al desagregar el *Recall* por subgrupo dentro del notebook, se constató un riesgo latente: el algoritmo se vuelve más preciso para identificar patrones masculinos de abandono, pudiendo subestimar causales específicas de deserción femenina. Acción Ética: Se prohíbe el uso de la variable **genero** en las decisiones automatizadas de asignación de becas de retención.

6.2 Sesgo por Escala Geográfica

Las Facultades Regionales metropolitanas —Buenos Aires (4.951 desertores), Haedo (447) y Avellaneda (115)— centralizan el volumen absoluto de registros del sistema. Existe el riesgo de que el modelo sufra de "centralismo estadístico", sepultando las realidades de sedes más pequeñas de la red donde las causales de desvinculación responden a factores de oferta horaria y no a la masividad áulica.

6.3 Dictamen Final y Despliegue Estratégico

El modelo se encuentra APROBADO PARA DESPLIEGUE OPERATIVO BATCH SEMESTRAL, condicionado a las siguientes pautas de supervisión humana:

1. Las predicciones actuarán como un sistema de recomendación de soporte, nunca como una decisión ejecutiva automatizada libre de control psicopedagógico.
2. Se estructurará un plan de reentrenamiento mandatorio cada 12 meses para mitigar la degradación del modelo (*Model Drift*) provocada por cambios en los planes de estudio.
3. Se restringirá el despliegue automático en aquellas Facultades Regionales donde la auditoría de equidad demuestre un Recall inferior al 70%, requiriendo para estas sedes un análisis con modelos locales.